

UNIVERSIDADE PRESBITERIANA MACKENZIE

PROJETO APLICADO II

ETAPA 1 E ETAPA 2

Título do Projeto:

Análise de Sentimento em Avaliações de Filmes

Integrantes do Grupo:

- FELIPE DOS SANTOS COSTA
- FELIPE YUJI NAKANISHI
- RAPHAEL CAMARGO EUGENIO DA SILVA
- VANESSA BIESEK BARTNICKI

São Paulo– 2026

PROJETO APLICADO II – ETAPA 1 E ETAPA 2

1. Grupo de Trabalho

O presente projeto será desenvolvido em grupo, conforme as orientações do componente curricular Projeto Aplicado II. O grupo será responsável pela definição do problema, aquisição e preparação dos dados, aplicação de técnicas de aprendizado de máquina, análise dos resultados e elaboração do relatório técnico.

2. Premissas do Projeto

2.1 Organização escolhida

A organização fictícia definida para o desenvolvimento deste projeto é denominada Analisa Filmes. A empresa atua na área de análise de dados aplicada ao setor de entretenimento, com foco na interpretação de opiniões e avaliações de usuários sobre filmes e séries.

O objetivo da Analisa Filmes é auxiliar produtoras, plataformas de streaming e distribuidoras de conteúdo audiovisual a compreender melhor a percepção do público sobre seus produtos. Por meio da análise automatizada de avaliações textuais, a empresa busca gerar insights que possam apoiar decisões estratégicas relacionadas a marketing, produção de conteúdo e experiência do usuário.

2.2 Problema de negócio

Plataformas de avaliação de filmes recebem diariamente milhares de comentários de usuários. A análise manual desse grande volume de dados torna-se inviável. Dessa forma, técnicas de Ciência de Dados e Processamento de Linguagem Natural (NLP) podem ser utilizadas para automatizar a análise dessas opiniões.

O problema abordado neste projeto consiste em desenvolver um modelo capaz de classificar automaticamente avaliações de filmes como positivas ou negativas, permitindo identificar o nível de satisfação do público.

2.3 Apresentação dos dados (metadados)

O projeto utilizará o dataset IMDb Movie Reviews, amplamente utilizado em estudos de análise de sentimento em textos.

Principais características da base de dados:

- Tipo de dado: texto (avaliações de filmes)
- Área de aplicação: Processamento de Linguagem Natural (NLP)
- Quantidade aproximada: 50.000 avaliações
- Tipo de classificação: sentimento positivo ou negativo

Cada registro do dataset contém o texto de uma avaliação escrita por um usuário e um rótulo que indica se o sentimento associado ao comentário é positivo ou negativo.

Esses dados serão utilizados para treinar e avaliar modelos de aprendizado de máquina capazes de identificar automaticamente o sentimento presente em novas avaliações.

Link do dataset no Kaggle: <https://www.kaggle.com/datasets/lakshmi25npathi/imdb-dataset-of-50k-movie-reviews>

O desenvolvimento do projeto será documentado por meio de um repositório no Github.

Link do repositório no Github: <https://github.com/rphl15/Avaliacao-de-Filmes>

3. Objetivos e Metas

Objetivo geral:

Desenvolver um modelo de aprendizado de máquina capaz de classificar automaticamente avaliações de filmes como positivas ou negativas, utilizando técnicas de processamento de linguagem natural.

Objetivos específicos:

- Realizar a aquisição e preparação da base de dados.

- Aplicar técnicas de limpeza e pré-processamento de texto.
- Converter os textos em representações numéricas utilizando Bag of Words ou TF-IDF.
- Treinar modelos de aprendizado de máquina para classificação de sentimento.
- Comparar o desempenho de diferentes algoritmos.
- Avaliar os resultados utilizando métricas de desempenho.

Metas do projeto:

- Implementar um pipeline completo de análise de texto.
- Treinar e avaliar modelos de classificação, com ênfase na Regressão Logística.
- Avaliar os modelos utilizando métricas como accuracy, precision e recall.
- Identificar o modelo com melhor desempenho para o problema proposto.

4. Base de Dados

Dataset: IMDb Movie Reviews (~50.000 reviews).

Link Kaggle: <https://www.kaggle.com/datasets/lakshmi25npathi/imdb-dataset-of-50k-movie-reviews>

Link GitHub: <https://github.com/rphl15/Avaliacao-de-Filmes>

5. Linguagem e Bibliotecas

A linguagem utilizada é Python, devido à sua aplicação em ciência de dados e NLP.

Bibliotecas:

- Pandas
- NumPy
- Matplotlib

- Seaborn
- NLTK
- re
- scikit-learn
- wordcloud

6. Análise Exploratória

Foram analisadas distribuição das classes, proporção dos dados, tamanho dos textos e padrões linguísticos.

6.1 Distribuição das classes

A Figura 1 apresenta a distribuição das classes da base de dados, indicando a quantidade de avaliações positivas e negativas.




Figura 1 – Distribuição das classes (positivo vs negativo)

Fonte: Elaborado pelos autores (2026)

Observa-se que a base de dados está balanceada, com aproximadamente a mesma quantidade de avaliações positivas e negativas. Esse equilíbrio é importante, pois evita viés no treinamento dos modelos de classificação.

6.2 Análise do tamanho das avaliações

A Figura 2 apresenta a distribuição da quantidade de palavras por avaliação, considerando os diferentes sentimentos.




Figura 2 – Densidade da quantidade de palavras por sentimento

Fonte: Elaborado pelos autores (2026)

A partir da análise, observa-se que a maioria das avaliações possui uma quantidade moderada de palavras, com algumas ocorrências de textos mais longos. Além disso, as distribuições de avaliações positivas e negativas são bastante semelhantes, indicando que o tamanho do texto não é, por si só, um fator determinante para o sentimento.

6.3 Análise de frequência de palavras

A Figuras 3 apresenta as nuvens de palavras (wordclouds) geradas a partir das avaliações positivas e negativas, respectivamente. Essa técnica permite visualizar as palavras mais frequentes em cada grupo de sentimento.

7. Tratamento dos Dados

Limpeza com regex, remoção de HTML, stopwords e normalização.

Conversão do target (positivo=1, negativo=0).

Vetorização com TF-IDF (5000 features).

Divisão treino/teste (80/20).

8. Método Analítico

Classificação supervisionada binária utilizando Regressão Logística.

Modelo adequado para dados textuais e alta dimensionalidade.

9. Avaliação do Modelo

Métricas utilizadas:

- Accuracy
- Precision
- Recall
- Matriz de confusão

10. Cronograma de Atividades (Estimativa)

Período	Atividade	Descrição	Responsável
09/03 – 12/03	Definição do projeto	Escolha do tema, definição da empresa fictícia e discussão do problema a ser resolvido	Todos
13/03 – 16/03	Pesquisa e escolha do dataset	Busca e análise de bases de dados adequadas para análise de sentimento	Felipe S / Felipe Y
17/03 –	Documentação	Elaboração do documento da Etapa 1 (Kick-off)	Vanessa

20/03	inicial		
21/03 – 23/03	Criação do repositório	Criação e organização inicial do repositório do projeto	Raphael
24/03 – 30/03	Exploração dos dados	Análise inicial da base de dados, identificação de estrutura, classes e distribuição	Felipe S
31/03 – 06/04	Pré-processamento de texto	Limpeza dos dados: remoção de stopwords, pontuação, tokenização e normalização	Felipe Y
07/04 – 13/04	Vetorização dos dados	Transformação do texto em representação numérica usando Bag of Words e TF-IDF	Felipe S / Felipe Y
14/04 – 20/04	Treinamento dos modelos	Implementação dos modelos de classificação (Naive Bayes, Regressão Logística e SVM)	Felipe S
21/04 – 27/04	Avaliação dos modelos	Avaliação utilizando métricas como accuracy, precision e recall	Felipe Y
28/04 – 05/05	Organização do repositório	Atualização do Github com códigos, notebooks e documentação	Raphael
06/05 – 15/05	Análise dos resultados	Interpretação dos resultados obtidos e comparação entre modelos	Todos
16/05 – 20/05	Elaboração do relatório final	Redação do documento final do projeto	Vanessa
21/05 – 23/05	Revisão geral	Revisão do código, documentação e organização dos materiais	Todos
24/05 – 25/05	Entrega final	Submissão do projeto e do relatório final	Todos