

UNIVERSIDADE PRESBITERIANA MACKENZIE

PROJETO APLICADO II

RELATÓRIO FINAL

Título do Projeto:

Análise de Sentimento em Avaliações de Filmes

Integrantes do Grupo:

- FELIPE DOS SANTOS COSTA
- FELIPE YUJI NAKANISHI
- RAPHAEL CAMARGO EUGENIO DA SILVA
- VANESSA BIESEK BARTNICKI

São Paulo– 2026

1. Introdução

O presente relatório técnico apresenta o desenvolvimento do projeto “Análise de Sentimento em Avaliações de Filmes”, elaborado no componente curricular Projeto Aplicado II do curso de Ciência de Dados.

O projeto teve como objetivo aplicar técnicas de Processamento de Linguagem Natural e aprendizado de máquina para classificar automaticamente avaliações de filmes como positivas ou negativas.

Ao longo das etapas do projeto foram realizados processos de aquisição e preparação de dados, análise exploratória, modelagem analítica, avaliação de desempenho e construção de uma proposta de aplicação de negócio baseada nos resultados obtidos.

Além do desenvolvimento técnico, o projeto também buscou aplicar conceitos de Data Storytelling, conectando os resultados analíticos a possíveis aplicações práticas no setor de entretenimento digital.

2. Grupo de Trabalho

O presente projeto será desenvolvido em grupo, conforme as orientações do componente curricular Projeto Aplicado II. O grupo será responsável pela definição do problema, aquisição e preparação dos dados, aplicação de técnicas de aprendizado de máquina, análise dos resultados e elaboração do relatório técnico.

3. Premissas do Projeto

3.1 Organização escolhida

A organização fictícia definida para o desenvolvimento deste projeto é denominada Analisa Filmes. A empresa atua na área de análise de dados aplicada ao setor de entretenimento, com foco na interpretação de opiniões e avaliações de usuários sobre filmes e séries.

O objetivo da Analisa Filmes é auxiliar produtoras, plataformas de streaming e distribuidoras de conteúdo audiovisual a compreender melhor a percepção do público sobre seus produtos. Por meio da análise automatizada de avaliações textuais, a empresa busca gerar insights que possam apoiar decisões estratégicas relacionadas a marketing, produção de conteúdo e experiência do usuário.

3.2 Problema de negócio

Plataformas de avaliação de filmes recebem diariamente milhares de comentários de usuários. A análise manual desse grande volume de dados torna-se inviável. Dessa forma, técnicas de Ciência de Dados e Processamento de Linguagem Natural (NLP) podem ser utilizadas para automatizar a análise dessas opiniões.

O problema abordado neste projeto consiste em desenvolver um modelo capaz de classificar automaticamente avaliações de filmes como positivas ou negativas, permitindo identificar o nível de satisfação do público.

3.3 Apresentação dos dados (metadados)

O projeto utilizará o dataset IMDb Movie Reviews, amplamente utilizado em estudos de análise de sentimento em textos.

Principais características da base de dados:

- Tipo de dado: texto (avaliações de filmes)
- Área de aplicação: Processamento de Linguagem Natural (NLP)
- Quantidade aproximada: 50.000 avaliações
- Tipo de classificação: sentimento positivo ou negativo

Cada registro do dataset contém o texto de uma avaliação escrita por um usuário e um rótulo que indica se o sentimento associado ao comentário é positivo ou negativo.

Esses dados serão utilizados para treinar e avaliar modelos de aprendizado de máquina capazes de identificar automaticamente o sentimento presente em novas avaliações.

Link do dataset no Kaggle: <https://www.kaggle.com/datasets/lakshmi25npathi/imdb-dataset-of-50k-movie-reviews>

O desenvolvimento do projeto será documentado por meio de um repositório no Github.

Link do repositório no Github: <https://github.com/rphl15/Avaliacao-de-Filmes>

4. Objetivos e Metas

Objetivo geral:

Desenvolver um modelo de aprendizado de máquina capaz de classificar automaticamente avaliações de filmes como positivas ou negativas, utilizando técnicas de processamento de linguagem natural.

Objetivos específicos:

- Realizar a aquisição e preparação da base de dados.
- Aplicar técnicas de limpeza e pré-processamento de texto.
- Converter os textos em representações numéricas utilizando Bag of Words ou TF-IDF.
- Treinar modelos de aprendizado de máquina para classificação de sentimento.
- Comparar o desempenho de diferentes algoritmos.
- Avaliar os resultados utilizando métricas de desempenho.

Metas do projeto:

- Implementar um pipeline completo de análise de texto.
- Treinar e avaliar modelos de classificação, com ênfase na Regressão Logística.
- Avaliar os modelos utilizando métricas como accuracy, precision e recall.
- Identificar o modelo com melhor desempenho para o problema proposto.

5. Base de Dados

Dataset: IMDb Movie Reviews (~50.000 reviews).

Link Kaggle: <https://www.kaggle.com/datasets/lakshmi25npathi/imdb-dataset-of-50k-movie-reviews>

Link GitHub: <https://github.com/rphl15/Avaliacao-de-Filmes>

6. Linguagem e Bibliotecas

A linguagem utilizada é Python, devido à sua aplicação em ciência de dados e NLP.

Bibliotecas:

- Pandas
- NumPy
- Matplotlib
- Seaborn
- NLTK
- re
- scikit-learn
- wordcloud

7. Análise Exploratória

Foram analisadas distribuição das classes, proporção dos dados, tamanho dos textos e padrões linguísticos.

7.1 Distribuição das classes

A Figura 1 apresenta a distribuição das classes da base de dados, indicando a quantidade de avaliações positivas e negativas.





Figura 1 – Distribuição das classes (positivo vs negativo)

Fonte: Elaborado pelos autores (2026)

Observa-se que a base de dados está balanceada, com aproximadamente a mesma quantidade de avaliações positivas e negativas. Esse equilíbrio é importante, pois evita viés no treinamento dos modelos de classificação.

7.2 Análise do tamanho das avaliações

A Figura 2 apresenta a distribuição da quantidade de palavras por avaliação, considerando os diferentes sentimentos.



Fonte: Elaborado pelos autores (2026)

7.3 Análise de frequência de palavras

[illegible]

Fonte: Elaborado pelos autores (2026)

Observa-se que nas avaliações positivas predominam palavras associadas a sentimentos favoráveis, como “best”, “great” e “good”, indicando satisfação dos usuários com os filmes analisados.

Nas avaliações negativas, destacam-se palavras como “bad”, “even” e “time”. Embora “bad” esteja diretamente associada a avaliações negativas, termos como “even” e “time” são palavras comuns no idioma e não carregam, isoladamente, um forte significado de sentimento, o que evidencia a importância do contexto na análise textual.

Além disso, observa-se que palavras como “film”, “movie” e “br” aparecem com frequência em ambas as nuvens de palavras, por se tratarem de termos genéricos relacionados ao domínio das avaliações. Esse comportamento indica que nem todas as palavras possuem valor discriminativo para o modelo, reforçando a necessidade do uso de técnicas como TF-IDF, que atribuem maior importância às palavras mais relevantes.

A partir dessa análise exploratória, torna-se possível realizar o tratamento adequado dos dados, conforme descrito na seção a seguir.

8. Tratamento dos Dados

Limpeza com regex, remoção de HTML, stopwords e normalização.

Conversão do target (positivo=1, negativo=0).

Vetorização com TF-IDF (5000 features).

Divisão treino/teste (80/20).

9. Métricas de Avaliação

Classificação supervisionada binária utilizando Regressão Logística.

Modelo adequado para dados textuais e alta dimensionalidade.

10. Avaliação do Modelo

Métricas utilizadas:

- Accuracy
- Precision

- Recall
- Matriz de confusão

11. Aplicação da Metodologia

O método analítico definido na etapa anterior foi aplicado à base de dados IMDb Movie Reviews, composta por aproximadamente 50.000 avaliações textuais de filmes.

Inicialmente, os dados passaram por pré-processamento, incluindo limpeza textual com expressões regulares, remoção de stopwords, caracteres especiais e normalização. Também foram removidas tags HTML.

Os textos foram convertidos em representações numéricas por meio da técnica TF-IDF, com até 5000 características.

O modelo utilizado foi Regressão Logística, adequado para classificação binária e análise de sentimentos. A base foi dividida em treino (80%) e teste (20%).

12. Medidas de Acurácia e Avaliação do Modelo

Foram utilizadas métricas de avaliação como acurácia, precisão, recall e matriz de confusão, com o objetivo de analisar de forma abrangente o desempenho do modelo de classificação.

A acurácia obtida foi de 0,89, indicando que aproximadamente 89% das previsões realizadas pelo modelo foram classificadas corretamente, o que evidencia um bom desempenho geral.

```
Acurácia: 0.89

Relatório de Classificação:

      precision    recall  f1-score   support

     0       0.90      0.87      0.88       4961
     1       0.88      0.90      0.89       5039

 accuracy          0.89          0.89      10000
 macro avg          0.89          0.89      10000
weighted avg          0.89          0.89      10000
```

Figura 4 – Acurácia

Fonte: Elaborado pelos autores (2026)

A matriz de confusão, apresentada na Figura 5, permite uma análise mais detalhada dos resultados, evidenciando a quantidade de classificações corretas e incorretas para cada classe.




Figura 5 – Matriz de Confusão

Fonte: Elaborado pelos autores (2026)

A partir da análise dessa matriz, observa-se que o modelo apresenta desempenho equilibrado entre as classes, com leve superioridade na identificação de avaliações positivas. Esse comportamento indica que o modelo possui boa capacidade de generalização, sendo eficaz na distinção entre sentimentos positivos e negativos.

13. Qualidade dos Dados e Limitações

A base de dados é balanceada, contribuindo para melhor desempenho do modelo.

Limitações:

- presença de palavras neutras
- variação no tamanho dos textos
- linguagem informal
- ausência de contexto semântico profundo

14. Interpretação dos Resultados

O modelo identifica padrões relevantes nos textos e apresenta boa capacidade de classificação.

A abordagem com TF-IDF e Regressão Logística mostrou-se adequada ao problema.

15. Aplicações de Negócio e Produto Analítico

15.1 Descrição do Produto

Sistema de análise de sentimento para classificar avaliações automaticamente.

15.2 Aplicação

- Monitoramento de opinião
- Apoio à decisão

15.3 Modelo de Negócio

Serviços de análise de dados, dashboards e APIs para empresas de entretenimento.

16. Storytelling do Projeto

Atualmente, plataformas de streaming, fóruns e sites especializados recebem milhares de avaliações de filmes diariamente. Esse grande volume de opiniões representa uma fonte valiosa de informação para empresas do setor audiovisual, mas também cria um desafio importante: como transformar milhares de comentários textuais em informações úteis para a tomada de decisão?

Nesse contexto, a empresa fictícia Analisa Filmes surge com a proposta de utilizar Ciência de Dados para compreender automaticamente a percepção do público sobre filmes e séries. O principal problema identificado foi a inviabilidade da análise manual das avaliações, tanto pelo volume de dados quanto pela velocidade com que novos comentários são publicados.

Para solucionar esse problema, o grupo desenvolveu um modelo de análise de sentimentos utilizando técnicas de Processamento de Linguagem Natural (NLP) e aprendizado de máquina. Inicialmente, foi realizada a limpeza e preparação dos textos,

incluindo remoção de caracteres especiais, stopwords e normalização das avaliações. Em seguida, os textos foram transformados em representações numéricas por meio da técnica TF-IDF, permitindo que os algoritmos identificassem padrões linguísticos relevantes.

Após os testes realizados, a Regressão Logística apresentou os melhores resultados para o problema proposto, alcançando aproximadamente 89% de acurácia. Além disso, as métricas de precisão, recall e matriz de confusão demonstraram equilíbrio na identificação de avaliações positivas e negativas, indicando consistência no desempenho do modelo.

Os resultados também permitiram identificar padrões relevantes no comportamento dos usuários. Palavras associadas a avaliações positivas, como “great”, “best” e “good”, apareceram com frequência em comentários favoráveis, enquanto termos como “bad” estiveram presentes em avaliações negativas. Ao mesmo tempo, observou-se que algumas palavras comuns, como “movie” e “film”, aparecem em ambos os grupos, evidenciando a importância do contexto na interpretação textual.

Do ponto de vista de negócio, a solução proposta apresenta potencial para aplicação em plataformas de streaming, produtoras e empresas de mídia digital. O modelo pode auxiliar no monitoramento automatizado da satisfação dos usuários, identificação rápida de avaliações negativas e análise da recepção do público em relação a determinados conteúdos. Dessa forma, os resultados obtidos podem apoiar decisões estratégicas relacionadas a marketing, recomendação de filmes e desenvolvimento de novos produtos audiovisuais.

Por fim, o projeto demonstra como técnicas de Ciência de Dados podem ser aplicadas em problemas reais, transformando grandes volumes de dados textuais em informações relevantes para análise e tomada de decisão.

17. Cronograma de Atividades (Estimativa)

Período	Atividade	Descrição	Responsável
09/03 – 12/03	Definição do projeto	Escolha do tema, definição da empresa fictícia e discussão do problema a ser resolvido	Todos
13/03 –	Pesquisa e	Busca e análise de bases de dados adequadas para	Felipe S /

16/03	escolha do dataset	análise de sentimento	Felipe Y
17/03 – 20/03	Documentação inicial	Elaboração do documento da Etapa 1 (Kick-off)	Vanessa
21/03 – 23/03	Criação do repositório	Criação e organização inicial do repositório do projeto	Raphael
24/03 – 30/03	Exploração dos dados	Análise inicial da base de dados, identificação de estrutura, classes e distribuição	Felipe S
31/03 – 06/04	Pré-processamento de texto	Limpeza dos dados: remoção de stopwords, pontuação, tokenização e normalização	Felipe Y
07/04 – 13/04	Vetorização dos dados	Transformação do texto em representação numérica usando Bag of Words e TF-IDF	Felipe S / Felipe Y
14/04 – 20/04	Treinamento dos modelos	Implementação dos modelos de classificação (Naive Bayes, Regressão Logística e SVM)	Felipe S
21/04 – 27/04	Avaliação dos modelos	Avaliação utilizando métricas como accuracy, precision e recall	Felipe Y
28/04 – 05/05	Organização do repositório	Atualização do Github com códigos, notebooks e documentação	Raphael
06/05 – 15/05	Análise dos resultados	Interpretação dos resultados obtidos e comparação entre modelos	Todos
16/05 – 20/05	Elaboração do relatório final	Redação do documento final do projeto	Vanessa
21/05 – 23/05	Revisão geral	Revisão do código, documentação e organização dos materiais	Todos
24/05 – 25/05	Entrega final	Submissão do projeto e do relatório final	Todos

18. Considerações Finais

O desenvolvimento deste projeto possibilitou a aplicação prática de conceitos fundamentais da Ciência de Dados, especialmente nas áreas de Processamento de Linguagem Natural (NLP), aprendizado de máquina e análise preditiva. A partir da utilização do dataset IMDb Movie Reviews, foi possível estruturar um pipeline completo de análise textual, contemplando etapas de aquisição, preparação, exploração, modelagem e avaliação dos dados.

Os resultados obtidos demonstraram que a combinação entre a técnica TF-IDF e o algoritmo de Regressão Logística apresentou desempenho satisfatório para o problema proposto, alcançando aproximadamente 89% de acurácia. Além disso, as métricas de precisão, recall e matriz de confusão evidenciaram equilíbrio na classificação das avaliações positivas e negativas, indicando consistência no comportamento do modelo.

Ao longo do projeto, também foi possível identificar limitações importantes relacionadas à análise de sentimentos em linguagem natural. Aspectos como sarcasmo, ambiguidades linguísticas e dependência do contexto textual ainda representam desafios relevantes para modelos tradicionais de classificação. Mesmo assim, os resultados mostraram que a solução desenvolvida possui potencial para aplicação em cenários reais de análise de opinião.

Do ponto de vista de negócio, o projeto evidenciou como técnicas de Ciência de Dados podem auxiliar empresas do setor audiovisual na interpretação automatizada da percepção do público. A solução proposta pode contribuir para monitoramento da satisfação dos usuários, identificação de tendências de avaliação e apoio à tomada de decisão estratégica em plataformas de streaming, produtoras e distribuidoras de conteúdo.

Além dos resultados técnicos, o projeto também proporcionou o desenvolvimento de competências relacionadas ao trabalho colaborativo, organização de atividades, documentação técnica e comunicação analítica por meio de Data Storytelling. Dessa forma, o trabalho permitiu integrar conhecimentos adquiridos ao longo do curso em uma aplicação prática alinhada às demandas atuais da área de Ciência de Dados.

19. Referências

Kaggle

KAGGLE. IMDb Dataset of 50K Movie Reviews. Disponível em:

<https://www.kaggle.com/datasets/lakshmi25npathi/imdb-dataset-of-50k-movie-reviews>.

Python

PYTHON SOFTWARE FOUNDATION. Python Language Reference. Disponível em:

<https://www.python.org/>.

Pandas

PANDAS DEVELOPMENT TEAM. Pandas Documentation. Disponível em:

<https://pandas.pydata.org/>.

NumPy

NUMPY DEVELOPERS. NumPy Documentation. Disponível em:

<https://numpy.org/>.

NLTK

NLTK PROJECT. Natural Language Toolkit Documentation. Disponível em:

<https://www.nltk.org/>.

Matplotlib

MATPLOTLIB DEVELOPMENT TEAM. Matplotlib Documentation. Disponível em:

<https://matplotlib.org/>.

Seaborn

WASKOM, Michael. Seaborn Documentation. Disponível em:

<https://seaborn.pydata.org/>.

GitHub

ANALISA FILMES. Repositório do Projeto – Avaliação de Filmes. Disponível em:

<https://github.com/rphl15/Avaliacao-de-Filmes>.